

Maestría en Inteligencia Artificial Aplicada / MNA / Tecnológico de Monterrey

Actividad en Equipos - Semanas 4 y 5:

Vectores Embebidos – HuggingFace

Análisis de Sentimiento: Amazon / Yelp / IMDb

Nombre(s): _____

Matrícula(s): _____

En la actividad de esta semana trabajarás en equipos con modelos de vectores embebidos de la plataforma HuggingFace. Los actuales LLM pueden generar vectores embebidos de cada token, palabra o enunciado que les proporcionen, el coste computacional y de uso de recursos hará la diferencia en el uso de cada uno de ellos.

Una primera manera de trabajar con estos modelos pre-entrenados, es generando un vocabulario a partir de tu conjunto de datos de entrenamiento. Posteriormente, cada palabra/token de tu vocabulario se sustituye por su correspondiente vector continuo/embebido. De manera predeterminada cuando no existe el vector para una palabra/token en particular se elige el vector más cercano en similaridad, o bien, se puede eliminar dicha palabra. Existen diversas propuestas para utilizar dichos vectores embebidos como entrada para modelos de aprendizaje automático.

En esta actividad vamos a comparar modelos de aprendizaje automático aplicando vectores embebidos desde cada palabra, a todo el comentario directamente.

En esta actividad trabajarás con los archivos de “Sentiment Labelled Sentences” de la UCI. Deberás descargarlos directamente de: <https://archive.ics.uci.edu/dataset/331/sentiment+labelled+sentences>

De dicha liga, descarga los archivos llamados amazon_cells_labelled.txt, imdb_labelled.txt y yelp_labelled.txt.

NOTA: Estos archivos no son exactamente iguales a los de la actividad de la semana pasada, por lo que debes descargarlos de la página de la UCI.

1. A partir de los 3 archivos descargados de la página de la UCI indicados, genera un solo DataFrame de Pandas llamado “df”. En particular, el archivo de datos de la IMDb requiere corregirse para obtener los 1000 registros que lo forman. Despliega el tamaño del DataFrame “df” y verifica que efectivamente tienes los 3000 registros con sus respectivas etiquetas.

PARTE I: Modelos basados en Aprendizaje:

2. Realiza un proceso de limpieza. Aplica el preprocesamiento que consideres adecuado a todos los comentarios. No elimines comentarios. Llama “Xclean” a los comentarios procesados y “y” a sus etiquetas.
3. Realiza una partición aleatoria con los porcentajes de entrenamiento, validación y prueba que consideres más adecuado. Llama a los conjuntos de dicha partición Xtrain, Xval, Xtest, ytrain, yval, ytest. Despliega la dimensión de dichos conjuntos. Usa una semilla de dicha partición para verificar su reproducibilidad.
4. Construye tu vocabulario a continuación:
 - a. Usa el conjunto de entrenamiento para generar tu vocabulario con un tamaño que consideres adecuado. Si lo deseas, puedes filtrar tu vocabulario por la frecuencia mínima de uso de cada palabra, así como por su longitud mínima en caracteres.
 - b. Indica el tamaño del vocabulario obtenido.
 - c. Con el vocabulario generado, filtra los conjuntos de entrenamiento, validación y prueba para que todos los comentarios usen solamente las palabras de este vocabulario. Llama train_X, val_X y test_X a estos tres conjuntos.

Procedamos ahora con los vectores embebidos de cada palabra y comentario de modelos preentrenados, en lugar de los vectores generados con las matrices Tf-idf de la actividad de la semana pasada.

5. La plataforma HuggingFace (<https://huggingface.co/>) nos da acceso a una variedad de modelo para obtener vectores embebidos en diferentes idiomas. En particular, podemos mencionar los siguientes tres:
 - a) [bge-base-en-v1.5](#)
 - b) [bge-large-en-v1.5](#)
 - c) [e5-base-v2](#)

Realiza un resumen de las principales características de cada uno de estos modelos.

6. Selecciona alguno de los modelos de HuggingFace para obtener vectores embebidos y obtener un nuevo diccionario clave-valor (key-value), donde la “clave” será cada palabra de tu vocabulario y el “valor” será su vector embebido de dimensión dada por el modelo seleccionado. Es recomendable que una vez que generes el nuevo vocabulario de vectores embebidos guardes dicho diccionario en un archivo (pickle, npz o el formato que consideres más adecuado). Además, apóyense entre los miembros del equipo para que puedan trabajar con diferentes modelos de vectores embebidos, buscando cuál puede dar el mejor desempeño. Muestren los primeros 3 elementos clave:valor del diccionario generado, así como el tamaño del vocabulario obtenido.
7. Una manera de utilizar los vectores embebidos con modelos de aprendizaje automático, es asignar a cada comentario el vector embebido que resulta de promediar todos los vectores embebidos de cada una de sus palabras/tokens. Así, en este ejercicio deberás generar los conjuntos de entrenamiento, validación y prueba de esta manera. Los llamaremos trainEmb, valEmb y testEmb, respectivamente. Es decir, ahora cada comentario es un solo vector de dimensión dada por el modelo de HuggingFace seleccionado. Muestra el tamaño de cada uno de los conjuntos trainEmb, valEmb y testEmb.
8. Calcula el número de tokens generados al obtener cada uno de los conjuntos trainEmb, valEmb y testEmb.
9. Utilizando los nuevos conjuntos embebidos de entrenamiento y validación del ejercicio anterior, realizar el entrenamiento con los modelos de regresión logística y bosque aleatorio (random forest). Para cada modelo muestra el valor de la exactitud (accuracy) y el reporte de sklearn dado por la función `classification_report()`. Verifica y justifica que no estén sobreentrenados ni subentrenados cada modelo.
NOTA: Diremos que un modelo no está sobreentrenado, si la diferencia entre entrenamiento y validación es menor al 3%, con respecto a la métrica de exactitud.

PARTE II: Método basado en modelos Preentrenados:

10. Ahora, como segunda parte de esta actividad:
 - a. Realiza la partición en Train-Val-Test con el mismo porcentaje, semilla y características utilizada en la primera parte de los 3000 comentarios tal como los obtuviste en la primer pregunta. Llamar a estos conjuntos X_train, X_val, X_test, y_train, y_val, y_test. Despliega la dimensión de dichos conjuntos.
 - b. Realiza la transformación a vectores embebidos de cada uno de los conjuntos X_train, X_val, X_test. Selecciona el mismo modelo de vector embebido que utilizaste en la primera parte. Indica la cantidad de tokens utilizados para generar cada uno de estos tres conjuntos de entrenamiento, validación y prueba.
 - c. Utiliza los modelos de regresión logística y bosque aleatorio (random forest) para este problema de clasificación. Para cada modelo muestra el valor de la exactitud (accuracy) y el reporte de sklearn dado por la función `classification_report()`. Verifica que no estén sub o sobre entrenados y compara tus resultados con los que obtuviste en la primera parte.
11. Con el mejor modelo obtenido, utiliza el conjunto de prueba correspondiente para obtener la matriz de confusión y el `classification_report()` de sklearn. Incluye tus comentarios.
12. Compáren los resultados obtenidos e incluyan sus comentarios finales de la actividad.